

Análisis y Predicción de la Criminalidad Violenta Mediante Modelos de Aprendizaje Automático sobre el Dataset Communities and Crime

Jose David Mesa Roldan
Andrés Alejandro Villota Villota
Thomas Ciro Correa
UNIVERSIDAD DE ANTIOQUIA

I. DESCRIPCIÓN DEL PROBLEMA

Es un problema orientado a las ciencias sociales estudiando la comunidad en uno de los ámbitos más complejos y controvertidos, tomada por medio de datos y crímenes registrados, entrevistas realizadas a diferentes comunidades pertenecientes a Estados Unidos en sus diferentes estados. Este Dataset cuenta con gran variedad de datos y características tomadas de registros que han sido almacenados desde 1990, con el fin de llevar un registro que contenga las diversas formas en que se han presentado los crímenes y qué variables han sido las más destacadas o son de importancia al momento en que estos fueron cometidos. El uso de técnicas de *Machine Learning* resulta especialmente útil. Los modelos de aprendizaje automático permiten analizar grandes volúmenes de datos multivariados y capturar patrones complejos, incluyendo relaciones no lineales entre variables. En este caso, al tratarse de un problema de regresión, el objetivo es construir un modelo capaz de predecir la tasa de crímenes violentos a partir de las características de cada comunidad, lo que puede servir como herramienta de apoyo para la toma de decisiones. La utilidad práctica de una solución basada en *Machine Learning* radica en su capacidad para generar predicciones y detectar patrones que no son evidentes a simple vista. Esto puede contribuir, por ejemplo, a priorizar recursos policiales, diseñar políticas públicas más efectivas o identificar comunidades en riesgo que requieran intervención. Además, este tipo de modelos puede ser utilizado para evaluar el impacto potencial de cambios en variables socioeconómicas, proporcionando una base más objetiva para la planificación estratégica.

II. DESCRIPCIÓN DEL DATASET

La base de datos utilizada corresponde al conjunto *Communities and Crime*, el cual integra información socioeconómica, datos de fuerzas policiales y estadísticas de criminalidad en comunidades de Estados Unidos. Este conjunto de datos está compuesto por un total de 1994 muestras, donde cada una representa una comunidad específica, y cuenta con 127 características. Las características abarcan diferentes aspectos relacionados con las condiciones de cada comunidad. Por un lado, se incluyen variables socioeconómicas provenientes del censo, como el ingreso familiar medio, el porcentaje de población

urbana o características demográficas. Por otro lado, se incorporan características relacionadas con las fuerzas del orden, como el número de policías por habitante o el porcentaje de oficiales asignados a unidades antidrogas. Finalmente, se incluye la variable objetivo del problema, que es la tasa de crímenes violentos per cápita, calculada a partir de delitos como homicidio, violación, robo y asalto. Se presentan datos faltantes en el conjunto original, particularmente en la variable relacionada con violaciones (rape), debido a inconsistencias en el reporte en algunos estados. Estas inconsistencias afectan el cálculo de la variable objetivo, por lo que las comunidades con estos datos incompletos fueron eliminadas del conjunto de datos, en lugar de aplicar una técnica de imputación. Todas las variables son de tipo numérico. Los datos fueron normalizados en el rango $[0, 1]$. Esta normalización se realizó mediante un método no supervisado basado en intervalos iguales (equal-interval binning). Como resultado, cada variable mantiene su distribución interna, aunque los valores extremos fueron ajustados: aquellos mayores a tres desviaciones estándar por encima de la media se asignaron a 1.00, y los menores a tres desviaciones estándar por debajo se asignaron a 0.00. Debido al formato de las características de los datos, que se encontraban en valores numéricos continuos, no se utilizaron técnicas como one-hot encoding o label encoding. La transformación principal aplicada fue la normalización, lo que permite que los algoritmos de aprendizaje automático trabajen con variables en una escala homogénea, aunque esto implica que las comparaciones directas entre diferentes atributos no siempre sean interpretables.

III. PARADIGMA DE APRENDIZAJE

Para el desarrollo del problema se eligió el paradigma de aprendizaje supervisado, ya que se cuenta con una variable objetivo definida, correspondiente a la tasa de crímenes violentos per cápita. Este enfoque es adecuado porque permite entrenar modelos a partir de datos etiquetados, donde se busca aprender la relación entre las variables de entrada y un valor numérico continuo. Dado que el objetivo es predecir una cantidad continua, el problema se clasifica en regresión, lo que justifica la selección de este tipo de modelos. Este enfoque permite capturar relaciones entre múltiples variables y la variable objetivo, facilitando la generación de predicciones

y el análisis del comportamiento de los datos. En este sentido, la elección del aprendizaje supervisado orientado a regresión responde directamente al problema y permite abordar de manera adecuada la estimación de la variable de interés.

IV. ESTADO DEL ARTE

El trabajo de McClendon y Meghanathan [1] utiliza la base de datos *Communities and Crime Unnormalized Dataset* de UCI para analizar y predecir patrones de criminalidad violenta, incluyendo variables como *ViolentCrimesPerPop*, homicidios, robos y asaltos por población. El enfoque corresponde a aprendizaje supervisado, específicamente regresión, dado que se busca predecir una variable continua. Para ello, los autores comparan tres algoritmos implementados en la herramienta WEKA: *Linear Regression*, *Additive Regression* y *Decision Stump*, aplicados sobre el mismo conjunto de características. La evaluación se realiza mediante métricas como *Correlation Coefficient*, *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, *Relative Absolute Error* y *Root Relative Squared Error*, donde el coeficiente de correlación mide la relación entre valores reales y predichos. Los resultados muestran que *Linear Regression* obtuvo el mejor desempeño, con mayor correlación y menores errores frente a los demás modelos. En consecuencia, los autores concluyen que la regresión lineal es la técnica más adecuada entre las evaluadas para predecir el crimen violento.

Yerpude y Gudu [2] usan la misma base de datos, pero buscan resolver un problema diferente, buscan resolver un problema de clasificación en que se identifiquen las características con mayor influencia en la tasa de crímenes, esta vez usando modelos más tradicionales de *Machine Learning*, como los *Decision Trees*, *Random Forest*, *Naive Bayes* y *Linear Regression*.

Para evaluar los modelos, usaron múltiples métricas de evaluación como el *Accuracy*, *Precision*, *Recall* y *F1 Score*, y como modelo de validación para los modelos se usó un *K-folds cross validation* con 10 Folds y en base a estas métricas se evaluaron todos los modelos, teniendo como resultado al *Random Forest* Como el modelo con mejor rendimiento general en todas las métricas de evaluación y con peor rendimiento en este caso fue el modelo de *Linear Regression*, en este caso el bajo desempeño de este modelo se debe a que es un problema de clasificación y no de regresión, y como variables que más influyen en la predicción del crimen se encontraron ‘*High crime*’ fueron ‘*NumUnderPov*’, ‘*PctNotSpeakEnglWell*’, ‘*LandArea*’ y ‘*NumbUrban*’

BIBLIOGRAFÍA

- [1] L. McClendon and N. Meghanathan, “Using machine learning algorithms to analyze crime data,” *Machine Learning and Applications an International Journal*, vol. 2, no. 1, pp. 1–12, Mar. 2015, doi: 10.5121/mlaij.2015.2101.
- [2] P. Yerpude and V. Gudur, “Predictive modelling of crime dataset using data mining,” *International Journal of Data Mining & Knowledge Management Process*, vol. 7, no. 4, pp. 43–58, Jul. 2017, doi: 10.5121/ijdkp.2017.7404.