

Análisis y Predicción de la Criminalidad Violenta Mediante Modelos de Aprendizaje Automático sobre el Dataset Communities and Crime

Jose David Mesa Roldan
Andrés Alejandro Villota Villota
Thomas Ciro Correa
UNIVERSIDAD DE ANTIOQUIA

I. DESCRIPCIÓN DEL PROBLEMA

El problema está orientado a la criminología estudiando la comunidad en uno de los ámbitos más complejos y controversiales, por medio de datos de crímenes registrados en diferentes comunidades pertenecientes a diversos estados de Estados Unidos. Este Dataset cuenta con gran variedad de datos y características tomadas de registros que han sido almacenados desde 1990, con el fin de llevar un registro que contenga las diversas formas en que se han presentado los crímenes e identificar qué variables han sido de mayor importancia al momento en que estos crímenes fueron cometidos.

El uso de técnicas de *Machine Learning* resulta especialmente útil. Los modelos de aprendizaje automático permiten analizar grandes volúmenes de datos multivariados y capturar patrones complejos, incluyendo relaciones no lineales entre variables. Debido a esto se abordó un problema mediante el paradigma de aprendizaje supervisado, específicamente desde un problema de regresión, ya el objetivo es construir un modelo capaz de predecir la tasa de crímenes violentos a partir de las características de cada comunidad y de la tasa de crímenes violentos registrada anteriormente, y debido a que se cuenta con los registros anteriores de la variable que se busca predecir, y de que esta variable es un valor numérico continuo este problema puede abordarse siguiendo el paradigma de aprendizaje supervisado para un problema de regresión.

La utilidad práctica de una solución basada en *Machine Learning* radica en su capacidad para generar predicciones y detectar patrones que no son evidentes a simple vista. Esto puede contribuir, por ejemplo, a priorizar recursos policiales, diseñar políticas públicas más efectivas o identificar comunidades en riesgo que requieran intervención. Además, este tipo de modelos pueden ser utilizados para evaluar el impacto potencial de cambios en variables socioeconómicas, proporcionando una base más objetiva para la planificación estratégica.

II. DESCRIPCIÓN DEL DATASET

La base de datos utilizados corresponden al conjunto *Communities and Crime*, el cual integra información socioeconómica, datos de fuerzas policiales y estadísticas de criminalidad en comunidades de Estados Unidos. Este conjunto de datos está compuesto por un total de 1994 muestras,

donde cada una representa una comunidad específica, y cuenta con 127 características. Las características abarcan diferentes aspectos relacionados con las condiciones de cada comunidad. Por un lado, se incluyen variables socioeconómicas provenientes del censo, como el ingreso familiar medio, el porcentaje de población urbana o características demográficas. Por otro lado, se incorporan características relacionadas con las fuerzas del orden, como el número de policías por habitante o el porcentaje de oficiales asignados a unidades antidrogas. Finalmente, se incluye la variable objetivo del problema, que es la tasa de crímenes violentos per cápita, calculada a partir de delitos como homicidio, violación, robo y asalto.

En el conjunto original de los datos, se presentaron en algunas comunidades inconsistencias en el conteo de crímenes violentos como violaciones (*rape*) lo que resultó en valores faltantes. Estas inconsistencias afectan el cálculo de la variable objetivo, por lo que las comunidades con estos datos incompletos fueron eliminadas del conjunto de datos, en lugar de aplicar una técnica de imputación. También se presentan varios datos faltantes de características como *County*, *Community*, *OtherPerCap* y de 22 características asociadas a datos del *LEMAS (Law Enforcement Management and Administrative Statistics)* en el caso de *County* y *Community* no es necesario realizar alguna técnica para tratar los datos faltantes, ya que solo son identificadores numéricos los cuales no serán usados en la tarea de regresión, *OtherPerCap* solo tiene un dato faltante, por lo que se reemplazará por el promedio de esta característica y respecto a los datos del *LEMAS*, debido a que hay demasiadas comunidades sin datos del *LEMAS*, las cuales representan aproximadamente el 84% del total de muestras, no se tomarán en cuenta estas características para la predicción de los crímenes violentos per cápita.

Todas las variables son de tipo numérico. Los datos fueron normalizados en el rango $[0, 1]$. Esta normalización se realizó mediante un método no supervisado basado en intervalos iguales (equal-interval binning). Como resultado, cada variable mantiene su distribución interna, aunque los valores extremos fueron ajustados: aquellos mayores a tres desviaciones estándar por encima de la media se asignaron a 1.00, y los menores a tres desviaciones estándar por debajo se asignaron a 0.00. Debido al formato de las características de los datos, que se encontraban en valores numéricos continuos, no se utilizaron técnicas como one-hot encoding o label encoding.

La transformación principal aplicada fue la normalización, lo que permite que los algoritmos de aprendizaje automático trabajen con variables en una escala homogénea, aunque esto implica que las comparaciones directas entre diferentes atributos no siempre sean interpretables.

III. ESTADO DEL ARTE

El trabajo de McClendon y Meghanathan [1] utiliza la base de datos *Communities and Crime Unnormalized Dataset* de UCI para analizar y predecir patrones de criminalidad violenta, incluyendo variables como *ViolentCrimesPerPop*, homicidios, robos y asaltos por población. El enfoque corresponde a aprendizaje supervisado, específicamente regresión, dado que se busca predecir una variable continua. Para ello, los autores comparan tres algoritmos implementados en la herramienta WEKA: *Linear Regression*, *Additive Regression* y *Decision Stump*, aplicados sobre el mismo conjunto de características. En este trabajo la evaluación se realizó mediante métricas como *Correlation Coefficient*, *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, *Relative Absolute Error* y *Root Relative Squared Error*, donde el coeficiente de correlación mide la relación entre valores reales y predichos. Los resultados muestran que *Linear Regression* obtuvo el mejor desempeño, con mayor correlación y menores errores frente a los demás modelos. En consecuencia, los autores concluyen que la regresión lineal es la técnica más adecuada entre las evaluadas para predecir el crimen violento.

Yerpude y Gudu [2] usan la misma base de datos de este proyecto, pero buscan resolver un problema diferente, buscan resolver un problema de clasificación en que se identifiquen las características con mayor influencia en la tasa de crímenes, esta vez usando modelos más tradicionales de *Machine Learning*, como los *Decision Trees*, *Random Forest*, *Naive Bayes* y *Linear Regression*.

Para evaluar los modelos, usaron múltiples métricas de evaluación como el *Accuracy*, *Precision*, *Recall* y *F1 Score*, y como modelo de validación para los modelos se usó un *K-folds cross validation* con 10 Folds y en base a estas métricas se evaluaron todos los modelos, teniendo como resultado al *Random Forest* Como el modelo con mejor rendimiento general en todas las métricas de evaluación y con peor rendimiento en este caso fue el modelo de *Linear Regression*, en este caso el bajo desempeño de este modelo se debe a que es un problema de clasificación y no de regresión, y como variables que más influyen en la predicción del crimen se encontraron ‘*High crime*’ fueron ‘*NumUnderPov*’, ‘*PctNotSpeakEnglWell*’, ‘*LandArea*’ y ‘*NumbUrban*’.

John y Markus [3] se enfocan en predecir la probabilidad de ocurrencia de ciertos crímenes mediante técnicas de aprendizaje supervisado, principalmente regresión lineal, utilizando la metodología CRISP-DM. Esta metodología fue seleccionada debido a que el dataset y sus etiquetas están compuestos completamente por valores numéricos, facilitando el análisis estadístico y predictivo. Los autores eligieron la regresión lineal en lugar de máquinas de vectores de soporte (SVM) porque permite interpretar con mayor claridad el impacto de cada atributo sobre la criminalidad. Gracias a los coeficientes

del modelo, fue posible identificar y ordenar las características más influyentes, proporcionando resultados más comprensibles y útiles para el análisis social. Durante el preprocesamiento realizaron limpieza de datos eliminando atributos irrelevantes, valores inexistentes y outliers. Para manejar datos faltantes aplicaron técnicas de sustitución como media, valores mínimos y máximos, imputación mediante SVM e imputación con k-NN. Después de realizar múltiples pruebas, concluyeron que la mejor estrategia fue combinar imputación SVM con Listwise Deletion, obteniendo un dataset más consistente y confiable. Para evaluar el rendimiento implementaron validación cruzada con 9 folds, reduciendo el sobreajuste y garantizando resultados más estables. La principal métrica utilizada fue el Relative Root Squared Error (RRSE), orientada a medir el error en las predicciones de los modelos de regresión. Adicionalmente, implementaron modelos de clasificación binaria (“High Crime” y “Low Crime”) mediante árboles de decisión, alcanzando precisiones superiores al 94% y llegando hasta un 96.77% tras ajustar parámetros del modelo. También analizaron indicadores estadísticos como $t\text{-Stat} > 2$ y $p\text{-Value} < 0.05$ para identificar las variables estadísticamente significativas dentro del modelo. Los resultados demostraron que los factores socioeconómicos tienen mayor efectividad para clasificar niveles generales de criminalidad que para predecir delitos específicos de manera individual. Finalmente, concluyeron que el dataset original modificado produjo mejores resultados que los subconjuntos obtenidos mediante Genetic Algorithm y Forward Selection. Aunque la regresión lineal presentó limitaciones para predecir delitos específicos como robos o hurtos de vehículos, sí permitió identificar relaciones importantes entre la criminalidad y variables socioeconómicas como pobreza, urbanización, viviendas vacías y niños nacidos de padres no casados, siendo esta última una de las variables más influyentes en múltiples pruebas.

El trabajo de Alves, Ribeiro y Rodrigues [4] aborda el problema de la predicción del crimen a partir de métricas urbanas y variables socioeconómicas mediante técnicas de aprendizaje estadístico. El enfoque utilizado corresponde a aprendizaje supervisado de tipo regresión, debido a que el objetivo consiste en predecir tasas de criminalidad usando variables continuas relacionadas con características urbanas y sociales. Los autores emplean principalmente el modelo Random Forest Regressor, argumentando que los métodos basados en ensamble manejan adecuadamente problemas de multicolinealidad y distribuciones no gaussianas presentes en este tipo de datos. La evaluación del modelo se realizó mediante validación cruzada, utilizando métricas de regresión como el coeficiente de determinación R al cuadrado, el cual mide la proporción de variabilidad explicada por el modelo, además del Mean Squared Error (MSE) y Root Mean Squared Error (RMSE), empleados para cuantificar el error de predicción. Adicionalmente, los autores analizaron la importancia relativa de las variables predictoras. Los resultados obtenidos muestran que Random Forest alcanzó un desempeño superior frente a modelos lineales tradicionales, identificando variables como desempleo e iletrismo entre las más influyentes en la predicción de criminalidad. Los autores concluyen que los métodos basados en ensambles permiten obtener modelos

más robustos y con mejor capacidad de generalización en problemas complejos relacionados con factores sociales y urbanos

IV. CONFIGURACIÓN EXPERIMENTAL

Como metodología de evaluación se eligió una validación cruzada KFold, con 8 Folds para probar diferentes hiperparámetros de los modelos, y se separaron los datos de entrenamiento y test en una proporción de 20% para test y 80% para train.

Para tratar el problema de los datos faltantes, a demás de eliminar las características se aplico una técnica de imputación de datos por SVM, a un dataset alternativo, y se entrenaron todos los modelos con ambos datasets.

Para resolver el problema predictivo de regresión se seleccionaron los modelos, Linear Regresion, k-nearest neighbors, Random Forest, Neuronal Network y support vector machine para cada modelo se seleccionaron distintos hiperparámetros siguiendo la metodología de validación cruzada kfold.

Para algunos modelos se variaron los hiperparámetros a la vez, se probaron todas las combinaciones posibles de estos en búsqueda de rendimiento, por tal razón no se escogieron muchos en terminos de cantidad ya que se priorizo encontrar aquellos que convergieran mejor.

Para el modelo de *Linear Regression*, se utilizaron los parámetros por defecto proporcionados por la implementación de *Scikit-learn*, ya que se trata de un modelo estadístico más simple que no requiere una optimización compleja de hiperparámetros en este contexto. El modelo fue entrenado directamente sobre los datos y posteriormente evaluado tanto en el dataset original como en el dataset imputado, permitiendo comparar su capacidad predictiva y comportamiento frente al tratamiento de valores faltantes.

Para el modelo de *Random Forest Regressor*, se utilizó una estrategia de optimización de hiperparámetros mediante *RandomizedSearchCV*, realizando 40 iteraciones sobre diferentes combinaciones posibles de parámetros. La selección se enfocó en maximizar la métrica R^2 , evaluando configuraciones relacionadas con la cantidad de árboles ($n_estimators$), la profundidad máxima (max_depth), las restricciones mínimas para dividir nodos ($min_samples_split$ y $min_samples_leaf$) y la proporción de variables utilizadas en cada división ($max_features$). Este proceso permitió encontrar una configuración equilibrada entre capacidad predictiva y control del sobreajuste, obteniendo como mejores valores: 160 árboles, profundidad máxima de 16, mínimo de 10 muestras para dividir nodos, mínimo de 3 muestras por hoja y uso del 60% de las características en cada división.

Para el modelo de *Support Vector Regression (SVR)*, se evaluaron múltiples combinaciones de hiperparámetros variando el tipo de *kernel* (*linear*, *polynomial* y *rbf*), diferentes valores de regularización C (0.01, 1 y 100), distintos grados para el kernel polinomial (3, 5 y 7) y el parámetro γ para el kernel RBF. Estas configuraciones fueron probadas sobre el dataset imputado con el objetivo de identificar la combinación con mejor capacidad predictiva y generalización. Tras la evaluación de los resultados, la configuración que obtuvo el

TABLE I
HIPERPARÁMETROS EVALUADOS Y MEJORES VALORES OBTENIDOS PARA
RANDOM FOREST REGRESSOR

Hiperparámetro	Valores evaluados	Mejor valor seleccionado
$n_estimators$	50 – 200 (pasos de 10)	160
max_depth	5 – 20 y None	16
$min_samples_split$	2 – 10	10
$min_samples_leaf$	1 – 10	3
$max_features$	sqrt, log2, 0.6, 0.8, 1.0	0.6

mejor desempeño fue *SVR Imputed (Kernel: Poly, $C=0.01$, $Deg = 3$)*, lo que indica que una función polinomial de baja complejidad y una regularización más estricta permitieron capturar de mejor manera las relaciones no lineales presentes en el conjunto de datos.

TABLE II
COMBINACIONES DE HIPERPARÁMETROS EVALUADAS PARA SUPPORT
VECTOR REGRESSION (SVR)

C	Kernel	Parámetros adicionales
1	lineal	–
1e-2	lineal	–
1e2	lineal	–
1	polynomial	degree = 3
1e-2	polynomial	degree = 3
1e2	polynomial	degree = 3
1	polynomial	degree = 5
1e-2	polynomial	degree = 5
1e2	polynomial	degree = 5
1	polynomial	degree = 7
1e-2	polynomial	degree = 7
1e2	polynomial	degree = 7
1	rbf	gamma = 1e-2
1e-2	rbf	gamma = 1e-2
1e2	rbf	gamma = 1e-2

Para el modelo de *K-Neighbors Regressor*, el hiperparámetro evaluado fue el número de vecinos más cercanos ($n_neighbors$), probando distintas configuraciones con los valores 5, 8, 10, 12, 15, 17, 20, 25, 30, 40 y 50. El objetivo de esta evaluación fue identificar la cantidad de vecinos que permitiera obtener el mejor equilibrio entre capacidad predictiva y generalización del modelo. Tras realizar las pruebas sobre ambos conjuntos de datos, se observó que el mejor desempeño se obtuvo con $n_neighbors = 15$, evidenciando que una menor cantidad de vecinos permitió capturar de mejor manera los patrones presentes tras el proceso de imputación.

TABLE III
VALORES EVALUADOS PARA EL HIPERPARÁMETRO $n_neighbors$ EN
K-NEIGHBORS REGRESSOR

Número de vecinos evaluados
5
8
10
12
15
17
20
25
30
40
50

Para el modelo *Artificial Neuronal Network*, se probaron diferentes arquitecturas de red, de 2 o 3 capas ocultas, en donde cada capa oculta con una cantidad en potencias de dos de nodos, como (32,16), (64,32), (128, 64),(128, 64, 32) y (256,128,64), también se probaron 3 funciones de activación de las capas ocultas para cada arquitectura de red, las funciones *Relu*, *tanh* y *Sigmoide*, buscando la combinación mas optima de estos hiperparametros se encontró que para el dataset con características eliminadas la mejor combinación de hiperparametros fue una arquitectura (256, 128, 64) con una función de activación Relu, y para el dataset con datos imputados, la mejor fue una arquitectura mas sencilla de (32, 16) junto a la función de activación Relu.

TABLE IV
COMBINACIONES PROBADAS ENTRE ARQUITECTURAS DE RED Y
FUNCIONES DE ACTIVACIÓN PARA UNA ARTIFICIAL NEURAL NETWORK
(MLP)

Arquitectura de Red	Función de activación
(32, 16)	Relu
(32, 16)	tanh
(32, 16)	sigmoid
(64, 32)	Relu
(64, 32)	tanh
(64, 32)	sigmoid
(128, 64)	Relu
(128, 64)	tanh
(128, 64)	sigmoid
(128, 64, 32)	Relu
(128, 64, 32)	tanh
(128, 64, 32)	sigmoid
(256,128,64)	Relu
(256,128,64)	tanh
(256,128,64)	sigmoid

El coeficiente de determinación R^2 fue utilizado como la métrica principal debido a que permite medir qué proporción de la variabilidad de la variable objetivo es explicada por el modelo. Esta métrica se calcula comparando el error residual del modelo frente a la variabilidad total de los datos, permitiendo identificar qué tan bien las predicciones representan el comportamiento real del fenómeno estudiado. Valores cercanos a 1 indican una alta capacidad explicativa, mientras que valores cercanos a 0 reflejan un desempeño limitado. La implementación de esta métrica fue especialmente útil en el proyecto, ya que permitió comparar directamente

modelos lineales y no lineales. Por otra parte, el MAE (Mean Absolute Error) fue empleado para medir el error promedio absoluto entre los valores reales y las predicciones generadas por cada modelo. Esta métrica resultó importante debido a que proporciona una interpretación directa del error promedio cometido por el sistema. Se utilizó la métrica RMSE (Root Mean Squared Error), la cual penaliza de manera más severa los errores grandes debido a la elevación al cuadrado de las diferencias entre valores reales y predichos. Esta característica permitió identificar modelos con comportamientos inestables o con presencia de predicciones extremadamente alejadas de los valores reales.

V. RESULTADOS DE EXPERIMENTACIÓN

El primer modelo a evaluar fue la *Linear Regresion* a la que se tomo una regresión lineal simple, por lo que no se evaluaron distintos hiperparámetros, pero al entrenarse tanto con el dataset de datos imputados como con el dataset de características eliminadas, se encontró que de acuerdo a la métrica R^2 , se encontró que la Regresión lineal entrenada con el dataset de datos imputados tuvo un mejor rendimiento

TABLE V
RESULTADOS DE DESEMPEÑO DE LOS MODELOS DE REGRESIÓN LINEAL

Modelo	Val_MAE	Val_RMSE	Val_R2
Regresión Lineal	0.098442	0.138712	0.646758
Regresión Lineal Imputada	0.096665	0.136752	0.658226
Modelo	Test_MAE	Test_RMSE	Test_R2
Regresión Lineal	0.094536	0.132840	0.631562
Regresión Lineal Imputada	0.088409	0.126226	0.667338

Para el modelo de *Random Forest* Luego de entrenar el modelo usando la metodología *RandomizedSearchCV*, Tanto con el dataset de datos imputados, como con el dataset con el que se eliminaron características, se encontro que el mejor modelo de Random Forest fue un modelo con 160 Arboles, numero minimo de muestras por split de 10, numero minimo de muestras por hoja 3 y el maximo numero de características a considerar de 16 y maxima profundidad del arbol de 16, y aunque con ambos datasets, se encontró el mismo modelo con los mismos hiperparametros con un mayor coeficiente de correlación, el dataset con los datos imputados tuvo un valor mayor en el coeficiente de correlación, por en el modelo entrenado con este dataset, se explica mejor la variabilidad de la variable objetivo.

TABLE VI
RESULTADOS DE DESEMPEÑO DE LOS MODELOS RANDOM FOREST

Modelo	Val_MAE	Val_RMSE	Val_R2
Random Forest	0.094271	0.135874	0.661363
Random Forest Imputed	0.092446	0.132585	0.678900
Modelo	Test_MAE	Test_RMSE	Test_R2
Random Forest	0.092133	0.134207	0.623941
Random Forest Imputed	0.087955	0.128013	0.657854

TABLE VII
HIPERPARAMETROS DEL MODELO DE RANDOM FOREST CON MEJOR
DESEMPEÑO EN LA METRICA R2

Hiperparámetro	Valor
num estimators	160
min samples per split	10
min samples per leaf	3
max features to split	0.6
max depth	16

Para los modelos de *Support Vector Machine*, luego de entrenar el modelo con todos los hiperparametros definidos y evaluarlos con el coeficiente de correlación R2, nuevamente en ambos datasets, se encontró que el modelo con mayor desempeño en esta métrica fue el mismo, un modelo con kernel polinomial de grado 3 y con un valor de C de 0.01, haciendo que se elija un menor numero de vectores de soporte.




Fig. 1. Valores del coeficiente de correlación para las maquinas de vectores de soporte

TABLE VIII
RESULTADOS DE DESEMPEÑO DE LOS MEJORES MODELOS SVR

Modelo	Val_MAE	Val_RMSE	Val_R2
SVR Imp	0.094	0.134	0.670
SVR	0.095	0.136	0.658
Modelo	Test_MAE	Test_RMSE	Test_R2
SVR Imp	0.087	0.124734	0.675
SVR	0.090	0.129842	0.648

Para el modelo de los *k-nearest neighbors*, luego de probar el modelo con ambos dataset, variando el numero de vecinos, se encontró nuevamente que el coeficiente de correlación en ambos dataset fue el mas alto para el mismo modelo, en este caso para 15 vecinos, que fue el tope de mejora, al aumentar los vecinos el modelo no mejoro en el coeficiente de correlación, y nuevamente el coeficiente de correlación fue mayor en el dataset de datos imputados.




Fig. 2. Valores del coeficiente de correlación para los modelos de k vecinos mas cercanos, con el dataset de datos imputados

Finalmente luego de probar las múltiples arquitecturas de red neuronal junto con funciones de activación, se encontraron esta vez, resultados diferentes para los hiperparametros de los modelos con mayor coeficiente de correlación en ambos datasets, siendo el mejor para el dataset en que se eliminaron características, fue una arquitectura de (256, 128, 64), con ReLU como función de activación y para el otro dataset fue una arquitectura (32,16) con función de activación ReLU también.




Fig. 3. Valores del coeficiente de correlación para los modelos de redes neuronales

TABLE IX
RESULTADOS DE DESEMPEÑO DE LOS MODELOS MLP

Modelo	Val_MAE	Val_RMSE	Val_R2
MLP Imputed (32,16) relu	0.098690	0.140209	0.640566
MLP (256,128,64) relu	0.095400	0.137407	0.651808
Modelo	Test_MAE	Test_RMSE	Test_R2
MLP Imputed (32,16) relu	0.086205	0.124981	0.673870
MLP (256,128,64) relu	0.087595	0.127651	0.659789

VI. REDUCCIÓN DE DIMENSIÓN

Con el objetivo de disminuir la complejidad del modelo y mejorar la interpretabilidad de los datos, se realizó un proceso de reducción de dimensión sobre el conjunto imputado. Primero se aplicó selección de variables basada en correlación y posteriormente se evaluaron técnicas de extracción lineal y no lineal de características.

A. Selección de variables

Se calculó la correlación absoluta entre cada variable predictora y la variable objetivo *ViolentCrimesPerPop*. Como criterio de eliminación, se consideraron irrelevantes aquellas variables con correlación menor a 0.05. Bajo este criterio se eliminaron las variables:

- PctSameState85
- PctVacMore6Mos
- PctWorkMomYoungKids
- LemasSwornFT
- householdsize
- racePctAsian
- PctEmplManu

La dimensionalidad pasó de 84 a 77 variables, eliminando aproximadamente el 8.3% de las características originales sin afectar significativamente el desempeño de los modelos.

Además, los mejores modelos obtenidos previamente fueron:

TABLE X
MEJORES MODELOS OBTENIDOS ANTES DE LA REDUCCIÓN DE DIMENSIÓN

Modelo	Test R2
SVR Imputed (Kernel Poly, C=0.01, Degree=3)	0.6752
MLP Imputed (32,16) relu	0.6739

Estos resultados sugieren que las relaciones presentes en el problema son predominantemente no lineales.

B. Reducción lineal mediante PCA

Posteriormente se aplicó PCA sobre el conjunto reducido de variables. Se evaluaron distintos porcentajes de varianza explicada para determinar el número adecuado de componentes principales.

TABLE XI
RESULTADOS OBTENIDOS UTILIZANDO PCA

Varianza	Componentes	SVR R2	MLP R2
85%	18	0.4889	0.6392
90%	24	0.4908	0.6313
95%	35	0.4841	0.6278
99%	56	0.4792	0.6268

Los resultados muestran que PCA logró reducir considerablemente la dimensionalidad; sin embargo, el desempeño disminuyó respecto a los modelos entrenados con las variables originales. El modelo MLP fue más robusto frente a esta reducción, alcanzando su mejor desempeño con 18 componentes y un R^2 de 0.6392.

Esto indica que una transformación lineal no logra preservar completamente la información relevante del problema.

C. Reducción no lineal mediante UMAP

Con el fin de capturar relaciones no lineales entre las variables, se aplicó UMAP utilizando una representación en dos dimensiones. Antes de aplicar el algoritmo, los datos fueron estandarizados.

Se evaluaron diferentes valores del parámetro $n_neighbors$ (5, 15 y 50), observándose que valores pequeños preservan

mejor la estructura local y generan agrupaciones más definidas, mientras que valores altos priorizan la estructura global.

Los modelos entrenados utilizando las dos componentes generadas por UMAP obtuvieron los siguientes resultados:

TABLE XII
RESULTADOS OBTENIDOS UTILIZANDO UMAP

Modelo	Test R2
SVR UMAP	0.4223
MLP UMAP	0.4814

Aunque UMAP redujo los datos a únicamente dos dimensiones, el desempeño obtenido fue inferior al alcanzado con PCA utilizando 18 componentes.

D. Comparación PCA vs UMAP

Al comparar ambas técnicas, se observa que PCA obtuvo mejores métricas predictivas que UMAP en este problema. Con PCA y 18 componentes, el modelo MLP alcanzó un R^2 de 0.6392, mientras que con UMAP en dos dimensiones obtuvo un R^2 de 0.4814.

Sin embargo, UMAP permitió representar los datos en un espacio extremadamente reducido conservando parte de la estructura no lineal del problema. Además, las visualizaciones generadas mostraron agrupaciones más claras y separaciones entre comunidades con distintos niveles de criminalidad.

Por tanto, PCA resultó más adecuado para mantener capacidad predictiva, mientras que UMAP fue más útil para explorar visualmente patrones complejos y relaciones no lineales en los datos.

E. Conclusiones

La reducción de dimensión permitió simplificar el conjunto de datos sin perder completamente la capacidad predictiva de los modelos.

La selección de variables eliminó características irrelevantes y redujo el número de variables de 84 a 77. Posteriormente, PCA logró una reducción importante de dimensionalidad manteniendo un desempeño aceptable, especialmente en el modelo MLP.

Por otro lado, UMAP evidenció la existencia de relaciones no lineales y agrupaciones naturales en los datos, aunque con una disminución mayor en las métricas predictivas debido a la representación en únicamente dos dimensiones.

En general, los resultados confirman que el problema de predicción de criminalidad presenta relaciones complejas y no lineales, lo cual explica el buen desempeño obtenido por modelos como SVR y redes neuronales. ““

BIBLIOGRAFÍA

- [1] L. McClendon and N. Meghanathan, “Using machine learning algorithms to analyze crime data,” *Machine Learning and Applications an International Journal*, vol. 2, no. 1, pp. 1–12, Mar. 2015, doi: 10.5121/mlaij.2015.2101.
- [2] P. Yerpude and V. Gudur, “Predictive modelling of crime dataset using data mining,” *International Journal of Data Mining & Knowledge Management Process*, vol. 7, no. 4, pp. 43–58, Jul. 2017, doi: 10.5121/ijdkp.2017.7404.

- [3] J. Ryan and M. Hofmann, “Communities and Crime: Creating a Data Mining Prediction Model – Identify Future Crimes given the Socioeconomic Background in an Area,” in *Small Devices, Big Data: Real Challenges*, pp. 75–82, 2018.
- [4] L. G. A. Alves, H. V. Ribeiro, and F. A. Rodrigues, “Crime prediction through urban metrics and statistical learning,” arXiv preprint arXiv:1712.03834, 2017.